

2026

PROJET 12

Gérez un projet d'infrastructure

NICOLAS PETIT | 23/01/2026 | OPENCLASSROOMS

SOMMAIRE

- 01 Contexte
- 02 Architecture Technique
- 03 Source de données
- 04 ETL (Extract Transform Load)
- 05 Stockage
- 06 Présentation des résultats
Power BI
- 07 Calculs et automatisations
- 08 Monitoring
- 09 Conclusion

SPORT DATA SOLUTIONS

1 - CONTEXTE

Contexte

En tant que Data Engineer chez Sport Data Solution, l'objectif est d'aider la direction de la start up à mettre en place un système d'avantages et de récompenses pour les salariés qui s'engagent de manière régulière dans une activité sportive.

Cette activité sportive se manifeste par 2 aspects :

- Le premier est de se rendre sur son lieu de travail avec un autre moyen de transport qu'un véhicule (transports en commun, vélo, etc...)
- Le second est de pratiquer un sport en dehors de l'activité professionnelle.



2 - ARCHITECTURE TECHNIQUE

Architecture Technique

Cette architecture permet de centraliser et de valoriser des données issues de différentes sources.

Les fichiers Excel stockés sur google drive sont ingérés automatiquement via Airbyte, tandis que des données simulées (Strava) sont générées avec Mimesis.

Les données brutes sont stockées dans un schéma de base de données PostgreSQL Raw.


Des pipelines Python assurent les calculs, nettoyages et transformations des données.

Les données enrichies sont ensuite chargées dans un schéma de base de données PostgreSQL Analytics, optimisé pour l'analyse.

Les résultats sont exploités via Power BI pour la visualisation.


Des notifications sont envoyées sur un canal Slack.

- L'ensemble des flux et services est monitoré par Prometheus, avec des tableaux de bord dans Grafana.



3 – SOURCES DE DONNEES

Données RH & Sportives



Données RH

Les données RH nous donnent les informations sur les salariés (id, adresse, moyen de déplacement, nom, prénom, etc...).

Données Sportives

Les données sportives nous donnent l'id salarié pour matcher avec les données RH et si le salarié pratique une activité sportive extra-professionnelle.


Récupération et envoi des données

Les fichiers excel cités ci-dessus sont envoyés, grâce à airbyte, dans une base de données PostgreSQL.

4 - ETL (Extract Transform Load)


ETL (Extract Transform Load)

Un ETL (Extract, Transform, Load) est un processus qui consiste à extraire des données depuis différentes sources, à les transformer (nettoyage, calculs), puis à les charger dans un système d'analyse et de reporting.




Extract

Extraction des données RH et Sportives des fichiers excel (sources de données)



Transform

- Calcul de la distance entre le domicile du salarié et l'adresse du lieu de travail
- Calcul de l'éligibilité à la prime + montant de la prime en fonction du moyen de transport salarié
- Calcul de l'éligibilité aux jours de bien-être en fonction du volume d'activités extra-professionnelles




Load

Envoi des données calculées dans la base de données qui servira de source pour l'outil de visualisation (Power BI)

5 - STOCKAGE (PostgreSQL)

Stockage (PostgreSQL)



PostgreSQL RAW

Le schéma RAW correspond à la zone d'atterrissage des données, stockées brutes, sans transformation.

Il permet de conserver l'historique et de rejouer les traitements si nécessaire.

PostgreSQL ANALYTICS

Le schéma ANALYTICS contient les données transformées et structurées selon les besoins métiers.

Il est optimisé pour l'analyse, le reporting et la consommation par des outils comme Power BI.


6 – PRESENTATION DES RESULTATS (POWER BI)

Présentation des résultats (Power BI)

L'objectif de ce tableau de bord et de donner un premier aperçu rapide et concret des principaux KPI :

- Vision des salariés éligibles à la prime et le coût total de la prime
- Salariés éligibles aux jours de bien-être et ceux proches d'y arriver

L'idée est ensuite de pouvoir rentrer dans le détail en faisant une analyse par BU, et ensuite par salarié.



Répartition des moyens de déplacement

73 (45,34%)

54 (33,54%)

20 (12,42%)

14 (8,7%)

moyen_de_deplacement

véhicule thermique/électri...

Vélo/Trottinette/Autres

Transports en commun

Marche/running

Éligibilité à la prime sportive par BU

prime_eligible

0

1

Nombre de id...

Finance

Support

Ventes

R&D

Marketing

Coût de la prime sportive par BU

Somme de prime_a...

50K

0K

Finance

Ventes

Support

Marketing

R&D


7 - CALCULS ET AUTOMATISATIONS

Calcul (Prime, Jours de bien-être)

Le pipeline calcule automatiquement deux avantages pour les employés. La Prime de Mobilité (5% du salaire brut) est attribuée selon deux critères : le moyen de déplacement et la distance entre le lieu de domicile et de travail.

Les employés qui utilisent un véhicule thermique/électrique sont automatiquement exclus, tandis que les autres (vélo, running, marche, transports en commun) doivent respecter une distance maximale variable selon leur sport (25 km pour le vélo et 15 km pour la marche).

Les Jours de Bien-être sont accordés aux employés ayant pratiqué au moins 15 activités sportives au cours des 12 derniers mois. Le système croise les données RH avec l'historique des activités Strava pour déterminer l'éligibilité. Les montants calculés et les statuts d'éligibilité sont ensuite stockés dans le schéma analytics pour exploitation dans Power BI.




Calcul (Distance du lieu de travail)

Le calcul de distance utilise l'API de géocodage Nominatim pour convertir les adresses textuelles en coordonnées GPS (latitude/longitude).

Pour chaque employé, le système géocode d'abord l'adresse du domicile, puis celle de l'entreprise, avec une pause d'1 seconde entre chaque requête pour respecter les limites de l'API.

En cas d'échec du géocodage (adresse introuvable), le système attribue automatiquement une valeur de 9999 km, garantissant ainsi que l'employé sera marqué comme non éligible à la prime sans bloquer le pipeline et mettre de côté ces adresses. Cette gestion d'erreur permet au processus de continuer même avec des données incomplètes ou invalides. L'objectif sera de rechercher, à la main, le potentiel problème avec l'adresse indiquée.




Automatisation (Cron Job)

Le pipeline ETL s'exécute en continu via une boucle infinie dans un conteneur Docker. Chaque cycle commence par une vérification systématique : le pipeline lance automatiquement une batterie de tests sur des schémas de test (`test_raw`, `test_analytics`) pour valider la logique métier avant de traiter les données de production.

Si les tests échouent, le cycle est abandonné et le système attend 5 minutes avant de réessayer. Une fois validé, le pipeline exécute l'extraction, la transformation et le chargement des données, puis attend 24 heures avant le prochain cycle.

Cette approche garantit une exécution quotidienne automatique sans intervention manuelle, tout en assurant la fiabilité grâce aux tests préalables. Les métriques Prometheus permettent de surveiller chaque cycle en temps réel.



8 – MONITORING

Monitoring

Monitoring

L'intérêt du monitoring est de pouvoir surveiller des pipelines ETL et des flux de données pour détecter des erreurs ou anomalies, et avoir une vision sur les performances des outils.



Prometheus

Prometheus

Prometheus est un outil open-source de collecte et stockage de métriques en temps réel, permettant d'alerter sur les anomalies dans les systèmes et pipelines.

Grafana


Grafana est une plateforme de visualisation qui transforme les métriques (ex. Prometheus) en tableaux de bord interactifs pour un suivi clair et rapide.

Monitoring Machine

Ici on retrouve le dashboard machine.

Il permet de suivre l'état des ressources (CPU, RAM, disque, réseau) pour anticiper les problèmes de performance ou de saturation avant qu'ils n'impactent les traitements.

Comme les problèmes de performances peuvent ne pas être directement liés au pipeline ou aux outils, il est intéressant de garder un oeil sur ces métriques.




Monitoring PostgreSQL

Ici on retrouve le dashboard

PostgreSQL.

Ce dashboard permet de surveiller la santé de la base de données (connexions, requêtes lentes, locks, taille des tables) afin d'assurer la performance et la disponibilité des données utilisées par les pipelines ETL.

Ici on peut filtrer directement sur la base de données concernée pour éviter le flux d'informations d'autres projets.




Monitoring Pipeline ETL

Ici on retrouve le dashboard du pipeline ETL.

Il permet de visualiser le flux des traitements, les temps d'exécution et les erreurs éventuelles pour détecter rapidement les anomalies et garantir la fiabilité des données.

Ici, comme le pipeline est dockerisé, on parle des métriques CPU, mémoire, réseau du conteneur.




Monitoring Pipeline ETL

Ici on retrouve le dashboard du pipeline ETL.

Il permet de visualiser le flux des traitements, les temps d'exécution et les erreurs éventuelles pour détecter rapidement les anomalies et garantir la fiabilité des données.

Ici, comme le pipeline est dockerisé, on parle des métriques CPU, mémoire, réseau du conteneur.



Logs Docker Pipeline ETL

Pour compléter le monitoring, on peut observer les logs du conteneur docker avec la commande :

`docker logs -f <nom_du_conteneur>`

Et il nous permet de voir les logs du code et donc :

- La réussite des tests
- L'envoi des notifications slack
- Le traitement des lignes
- Et la bonne réussite, ainsi que l'attente du prochain cycle.

```
Lancement du script main unifié
Lancement du pipeline unifié.
Schemas 'raw' and 'dev' ensured.
Début du cycle ETL...
Running pre-cycle systematic verification...
Lancement du script main unifié
=== STARTING ISOLATED TEST PIPELINE ===
Switched to test schemas: test_raw, test_dev
Mocked Slack notifications.
Schemas 'test_raw' and 'test_dev' ensured.
Mocking Airbyte Data...
Mock data inserted into test_raw.
--- 1. Extracting Data ---
Extraction OK.
--- 2. Generating Activities ---
Generating 2 activities over 30 days...
Generation OK.
--- 3. Processing & Notifying ---
Processing 2 activities for notification...
Inserted 2 rows into test_raw.strava_activities
Sending Slack notifications...
MOCKED SLACK: Would send notification for Jane Smith
MOCKED SLACK: Would send notification for John Doe
Notification/Insertion OK.
--- 4. Transformation ---
Traitement de la ligne 0/3
Transformation OK.
Wellness column check OK.
--- 5. Loading ---
Loading OK.
EMP003 eligibility check (Car user -> Not Eligible) OK.
VERIFICATION SUCCESSFUL: Pipeline Logic Validated.
Restored production schemas: raw, dev
Restored real Slack notifications.
=== END ISOLATED TEST PIPELINE ===
Verification successful. Proceeding to production ETL.
Generating 5 activities over 30 days...
Processing 5 activities for notification...
Inserted 5 rows into raw.strava_activities
Sending Slack notifications...
Traitement de la ligne 0/161
Traitement de la ligne 10/161
Traitement de la ligne 20/161
Traitement de la ligne 30/161
Traitement de la ligne 40/161
Traitement de la ligne 50/161
Traitement de la ligne 60/161
Traitement de la ligne 70/161
Traitement de la ligne 80/161
Traitement de la ligne 90/161
```

```
Synced 1117 activities to dev.dev_strava_activities
Cycle ETL terminé avec succès.
Waiting for 1 day before next cycle...
```

9 - CONCLUSION